

Evaluación de impacto

Conceptos fundamentales y métodos

Investigación Empírica y Cuantitativa para las políticas públicas — Maestría Derecho y Gobierno
- UBA

29/07/2026

Evaluación de impacto

De la pregunta causal a los métodos

Basado en Gertler, Martinez, Premand, Rawlings y Vermeersch, *La evaluación de impacto en la práctica*, 2.ª ed. (Banco Mundial / BID), caps. 1-8

Hoja de ruta

Parte I — ¿Por qué y qué evaluamos?

- Qué es una evaluación de impacto · prospectiva vs. retrospectiva · eficacia vs. efectividad · ética
- Teoría del cambio y cadena de resultados

Parte II — El problema causal

- Inferencia causal, fórmula básica y contrafactual
- Las dos estimaciones falsas del contrafactual

Parte III — Los métodos

- Asignación aleatoria · Regresión discontinua · Diferencias en diferencias · Pareamiento

¿Qué es una evaluación de impacto?

Una **evaluación de impacto** mide los cambios en el bienestar de los individuos que se pueden **atribuir** a un proyecto, programa o política específicos.

El sello distintivo es la **atribución**: el reto es identificar la relación causal entre el programa y los resultados de interés.

Responde a una pregunta muy precisa:

¿Cuál es el **impacto** (o efecto causal) de un programa en un resultado de interés?

Se distingue así del **monitoreo** (seguimiento continuo de insumos, actividades y productos) y de las evaluaciones que responden preguntas **descriptivas** o **normativas**.

Prospectiva vs. retrospectiva

Prospectiva

Se diseña y elabora **antes** de implementar el programa, y se incorpora a su implementación.

- Permite recolectar **datos de línea de base**
- Obliga a definir objetivos y medidas de éxito al planificar
- Los grupos de tratamiento y comparación se definen **ex ante**

Retrospectiva

Evalúa el impacto **después** de implementado el programa; los grupos se generan **ex post**.

- Depende de datos preexistentes y de reglas de asignación claras
- Su viabilidad **nunca está garantizada**
- Suele apoyarse en métodos cuasi-experimentales y supuestos más fuertes

Las prospectivas tienen más probabilidad de generar contrafactuales válidos.

Eficacia vs. efectividad

Estudios de eficacia

¿El programa **puede** funcionar en condiciones ideales?

- Entornos controlados, escala piloto
- Fuerte participación técnica de los investigadores
- Sirven como **prueba de concepto**
- Generalización limitada

Estudios de efectividad

¿El programa **realmente** funciona en condiciones normales?

- Vías de implementación regulares, escala real
- Resultados generalizables a la población de interés
- Es lo que le importa a quien decide políticas

Si un programa no genera impacto bajo condiciones cuidadosamente manejadas, difícilmente funcione desplegado en circunstancias normales. Pero lo inverso no es automático: los cálculos de costo-beneficio cambian con la escala.

Consideraciones éticas

- Punto de partida: **invertir recursos públicos en programas de efectividad desconocida también plantea un problema ético**. La falta de evaluación no es neutral.
- Principio básico: **no negar ni retrasar** intervenciones de beneficio conocido únicamente en función de los objetivos de la evaluación.
- Las evaluaciones **no deberían dictar cómo se asignan los beneficios**: deben ajustarse a reglas de asignación equitativas y transparentes. Los reparos éticos suelen provenir de las reglas de operación del programa, no de la evaluación en sí.
- Cuando los recursos son limitados, la **asignación aleatoria** satisface el requisito de que todos los elegibles tengan la misma oportunidad de ser destinatarios.
- Es además **investigación con seres humanos**: comités de ética, consentimiento, plan de análisis previo, registro del estudio, datos y códigos replicables.

La teoría del cambio

Una **teoría del cambio** es la descripción de cómo se supone que una intervención conseguirá los resultados deseados: expone la **lógica causal** de cómo y por qué un programa logrará los resultados previstos.

- Describe una **secuencia de eventos** que generan resultados
- Explicita **condiciones y supuestos** necesarios para que el cambio ocurra
- Mapea las intervenciones a lo largo de las vías causales

Es **la base de cualquier evaluación de impacto**, porque la evaluación es causal por definición. El mejor momento para construirla es al **comienzo del diseño**, con todas las partes interesadas, para forjar una visión común de los objetivos y del camino para alcanzarlos.

Cap. 2.

La cadena de resultados

Una **cadena de resultados** establece la secuencia de insumos, actividades y productos que previsiblemente mejorarán los resultados y los resultados finales.

INSUMOS Recursos financieros, humanos y de otro tipo movilizados para realizar las actividades.
ACTIVIDADES Acciones o trabajo realizado para transformar los insumos en productos.
PRODUCTOS Bienes y servicios tangibles, bajo control directo de la agencia ejecutora.
RESULTADOS Uso de los productos por la población beneficiaria. No totalmente bajo control de la agencia.
RESULTADOS FINALES Objetivos de largo plazo. Dependen de múltiples factores.

Implementación (LADO DE LA OFERTA)

Resultados (LADO DE LA DEMANDA + LADO DE LA OFERTA)

II. El problema causal

Correlación no es causalidad



Muchas preguntas de política son de causa y efecto: ¿la formación docente mejora los puntajes? ¿las transferencias condicionadas mejoran la salud infantil? Observar que dos cosas se mueven juntas **no alcanza** para establecer causalidad.

La fórmula básica de la evaluación de impacto

Las evaluaciones de impacto establecen **hasta qué punto un programa —y sólo ese programa— provocó un cambio en un resultado.**

$$\Delta = (Y \mid P = 1) - (Y \mid P = 0)$$

El impacto causal Δ de un programa P sobre un resultado Y es la diferencia entre el resultado **con** el programa ($P = 1$) y **el mismo resultado sin** el programa ($P = 0$), para **la misma unidad, en el mismo momento del tiempo.**

La fórmula vale para **cualquier unidad de análisis** que pueda beneficiarse del programa o verse afectada por él:

personas • hogares • comunidades • empresas • escuelas • hospitales • juzgados

Y para **cualquier resultado** Y relacionado con el programa.

Cap. 3.

El problema del contrafactual

El **contrafactual** es lo que habría ocurrido —cuál habría sido el resultado Y para un participante del programa — **en ausencia** del programa P .

El problema: es **imposible medir al mismo sujeto en dos realidades distintas al mismo tiempo**. En cualquier momento, o participó o no participó.

- $(Y \mid P = 1) \rightarrow$ **se observa**: basta medir el resultado del participante
- $(Y \mid P = 0) \rightarrow$ **no se observa**: hay que **estimar**lo

El ejemplo de la píldora. El "señor Desafortunado" toma una píldora y muere cinco días después. ¿La píldora lo mató? Quizá ya estaba muy enfermo cuando la tomó. Para inferir causalidad hay que establecer **qué le habría pasado si no la hubiera tomado**. Eso es el contrafactual.

Del clon perfecto al grupo de comparación

La solución ideal sería un **clon perfecto** del participante: idéntico en todo, salvo que no recibe el programa. Comparamos y listo.


En la realidad los clones perfectos no existen —ni siquiera entre gemelos idénticos. Por eso, en vez del impacto sobre un individuo, se estima el **impacto promedio sobre un grupo**.

Un **grupo de comparación válido**: (1) tiene las mismas características, **en promedio**, que el grupo de tratamiento en ausencia del programa; (2) **no es afectado** por el programa, ni directa ni indirectamente; y (3) **reaccionaría al programa de la misma manera** que el grupo de tratamiento, si fuera objeto de él.

Sin un grupo de comparación que estime con precisión el contrafactual, el impacto estimado **no es válido**: en términos estadísticos, es **sesgado**.

Contrafactual falso 1: comparación antes-después

Usa como contrafactual el **resultado del propio grupo de tratamiento antes** del programa. Supone que, sin programa, nada habría cambiado.



Si hubo sequía, el verdadero contrafactual es **D** y el impacto es mayor que A-B. Si mejoraron las lluvias, es **C** y el impacto es menor. Sin controlar por todos los factores que varían en el tiempo, el resultado de línea de base **casi nunca** es una buena estimación del contrafactual.

Adaptado del gráfico 3.3.

Contrafactual falso 2: inscritos vs. no inscritos

Compara a quienes **eligieron inscribirse** con quienes, siendo elegibles, **eligieron no hacerlo**.

Ejemplo: un programa de orientación profesional para jóvenes desempleados. Dos años después, los inscritos ganan el doble que los no inscritos. ¿Impacto del programa?

Probablemente no. Los dos grupos son **distintos de entrada**:

- Quienes se inscribieron pueden estar más motivados o esperar un retorno alto
- Quienes no lo hicieron pueden ser jóvenes desanimados
- El mismo problema aparece si la admisión depende de **preferencias no observadas de los administradores** (por ejemplo, una entrevista)

El **sesgo de selección** se produce cuando los motivos por los que un individuo participa en un programa están **correlacionados con los resultados**, incluso en ausencia del programa.

Eliminarlo es uno de los objetivos centrales de toda evaluación de impacto.

III. Los métodos

Asignación aleatoria

En la **asignación aleatoria**, cada unidad elegible tiene la misma probabilidad de ser seleccionada para el tratamiento, lo que asegura la equivalencia entre los grupos de tratamiento y comparación tanto en las características **observables** como en las **no observables**.

Población de unidades elegibles

La asignación aleatoria conserva las características ✓ ↘ La asignación aleatoria conserva las características

Grupo de tratamiento
asignado al tratamiento

Grupo de comparación
no asignado al tratamiento

Con un número suficientemente grande de unidades, cualquier característica de la población se transfiere a ambos grupos: si el 40% eran mujeres, ~40% lo serán en cada grupo. Lo mismo vale para lo difícil de observar —motivación, preferencias, rasgos de personalidad—. Por eso se la considera la **regla de oro** de la evaluación de impacto.

Adaptado del gráfico 4.1.

Validez interna y validez externa

Validez interna

Una evaluación tiene validez interna si proporciona una **estimación precisa del contrafactual** mediante un grupo de comparación válido.

El impacto estimado está libre de factores de confusión.

Se asegura mediante la **asignación aleatoria del tratamiento**.

Son **dos usos distintos del azar**. Se puede tener validez interna sin validez externa (asignación aleatoria en una muestra no representativa) y viceversa (muestra representativa pero grupo de comparación inválido). A veces hay que **equilibrar** entre ambas.

Validez externa

Una evaluación tiene validez externa si la **muestra representa con precisión a la población de unidades elegibles**.

Los resultados pueden generalizarse al conjunto de la población.

Se asegura mediante el **muestreo aleatorio**.

¿Cuándo puede aplicarse?

La asignación aleatoria funciona como regla de asignación en **dos escenarios**:

1. La población elegible es mayor que las plazas disponibles

Cuando la demanda supera la oferta, un sorteo selecciona el grupo de tratamiento. Quienes ganan el sorteo son tratamiento; el resto, comparación.

Ej.: un programa financia bibliotecas para un tercio de las escuelas públicas del país.

2. El programa se amplía de manera progresiva

Cuando se despliega por etapas, se aleatoriza el **orden** en que los beneficiarios —todos igualmente merecedores— reciben el programa. Los que entran más tarde son el grupo de comparación de los primeros.

Ej.: capacitar a 15.000 enfermeros en tres años, un tercio por año.

Ventaja adicional: es una regla **justa, transparente y difícil de manipular**, que protege a los administradores de acusaciones de favoritismo.

Diseño de regresión discontinua (DRD)

El **DRD** es adecuado para programas que usan un **índice continuo** para clasificar a los participantes potenciales y que tienen una **puntuación límite** en ese índice, la cual determina quién tiene derecho a beneficiarse del programa.


Cuatro condiciones:

1. El índice debe clasificar a las unidades de manera **continua** (índice de pobreza, puntajes de pruebas, edad; **no** categorías discretas como "empleado / desempleado")
2. Debe haber una **puntuación límite claramente definida**
3. La puntuación límite debe ser **única para el programa** de interés
4. La puntuación **no debe poder manipularse** por encuestadores, beneficiarios, administradores ni políticos

El DRD estima el impacto **en torno al límite**: diferencia entre el resultado promedio de las unidades del lado tratado y el del lado no tratado.


DRD: la situación en la línea de base

Programa que subsidia fertilizantes a fincas de **menos de 50 hectáreas**. Antes del programa, las fincas pequeñas producen menos que las grandes: la relación es **continua**, sin saltos.



Adaptado del gráfico 6.1.

DRD: la situación en el seguimiento



Las fincas **demasiado grandes** para inscribirse estiman el contrafactual de las que eran **justo lo suficientemente chicas**. Como el impacto se identifica en la vecindad del límite, es un efecto **local** (LATE): no sabemos qué pasa con fincas de 10 o 20 ha. A cambio, **ninguna unidad elegible queda sin tratamiento** por razones de evaluación.

Adaptado del gráfico 6.2.

Diferencias en diferencias (DD)


El método de **diferencias en diferencias** compara los **cambios** en los resultados a lo largo del tiempo entre unidades inscritas en un programa (tratamiento) y unidades no inscritas (comparación). Permite corregir cualquier diferencia entre los grupos que sea **constante a lo largo del tiempo**.

La idea: combinar las **dos estimaciones falsas** del contrafactual para producir una mejor.

- La **primera diferencia** (antes-después en el grupo tratado) controla por todo lo que es fijo en ese grupo... pero deja en pie los factores que **varían en el tiempo**
- La **segunda diferencia** (antes-después en el grupo no tratado) captura justamente esos factores variables en el tiempo
- Restando una de otra se elimina una fuente importante de sesgo

Se anulan no sólo las características **observables** invariantes en el tiempo, sino también las **no observables** (rasgos de personalidad, historia familiar, cultura institucional).

DD: el cálculo



	Después	Antes	Dif.
Tratamiento	0,74	0,60	0,14
Comparación	0,81	0,78	0,03
Diferencia	-0,07	-0,18	0,11

$$\$DD = (B-A) - (D-C)\$$$

Equivalentemente:

$$\$DD = (B-D) - (A-C)\$$$

Adaptado del gráfico 7.1 y el cuadro 7.1.

DD: el supuesto crítico

Supuesto de tendencias iguales: en ausencia del programa, los resultados del grupo de tratamiento habrían evolucionado siguiendo la **misma tendencia** que los del grupo de comparación (el trayecto A → E del gráfico anterior).

Los grupos **no necesitan** tener el mismo nivel antes de la intervención. Necesitan tener la misma **trayectoria**. Y ese supuesto **no es verificable directamente** —el contrafactual sigue siendo inobservable—. Cuatro formas de ponerlo a prueba:

1. **Tendencias previas:** verificar que los dos grupos se movían en paralelo antes del programa
2. **Prueba de placebo con grupo falso:** estimar el DD con un grupo que sabemos que no fue afectado; debería dar cero
3. **Prueba de placebo con resultado falso:** estimar el impacto sobre un resultado que el programa no puede afectar
4. **Grupos de comparación alternativos:** si ambos son válidos, el impacto estimado debería ser similar

Pareamiento (*matching*)

El **pareamiento** utiliza grandes bases de datos y técnicas estadísticas para construir el mejor grupo de comparación posible **sobre la base de características observables**.

Para cada unidad tratada se busca una unidad no tratada (o un conjunto) con características lo más parecidas posible.

Unidades tratadas

Edad	Género	Meses desemp.	Sec.
19	1	3	0
35	1	12	1
24	1	8	1
27	0	4	1
41	0	17	1


Unidades no tratadas

Edad	Género	Meses desemp.	Sec.
19	1	3	0
38	0	1	0
24	1	8	1
27	0	4	0
41	0	17	1

Problema: la **maldición de la dimensionalidad**. Con pocas características se encuentran parejas, pero se dejan afuera variables

Puntaje de propensión y rango común

El **puntaje de propensión** es la probabilidad estimada de que una unidad se inscriba en el programa, dadas sus características observables **de línea de base**. Seorean las unidades con puntajes más cercanos.



En las **colas** falta superposición:

- Inscritos con puntaje cercano a **1** no tienen par
- No inscritos con puntaje cercano a **0** tampoco

El pareamiento estima entonces un efecto **local** (LATE), sólo sobre el rango común.

Límite de fondo: sólo controla por lo **observable**.

Si la inscripción depende de algo no observado, el sesgo persiste.

Pareamiento combinado con otros métodos

Los usos más convincentes del pareamiento son los que **no lo usan solo**.

Diferencias en diferencias pareadas

Si hay datos de línea de base sobre los resultados, se combinan ambos métodos:

1. Parear a partir de características observables **de línea de base**
2. Calcular el cambio antes-después de cada unidad inscrita (*primera diferencia*)
3. Calcular el cambio antes-después de su comparación pareada (*segunda diferencia*)
4. Restar la segunda de la primera
5. Promediar esas dobles diferencias

Ventaja: al pareamiento (que controla lo observable) se le suma el DD, que además neutraliza las **características no observables constantes en el tiempo**.

Síntesis: elegir el método

Método	Qué necesita	Estima
Asignación aleatoria	Exceso de demanda o despliegue por etapas	Impacto promedio (ATE)
Regresión discontinua	Índice continuo + límite claro y no manipulable	Efecto local en el límite (LATE)
Diferencias en diferencias	Datos antes y después en ambos grupos	Impacto bajo tendencias iguales
Pareamiento	Base de datos rica en características observables	Impacto sobre el rango común

La elección **no es una preferencia teórica**: depende de las características operativas del programa —recursos disponibles, criterios de elegibilidad y plazos de implementación—. Reglas de asignación claras, equitativas y transparentes casi siempre permiten encontrar un buen diseño de evaluación.